

Investigacao Voz Morgan

Análise Autónoma · 08/08/2026

Investigação Voz Morgan — 8 Agosto 2026

Objetivo: Encontrar a arquitectura de voz ideal para o Morgan — natural, emocional, estilo "irmão", PT-PT.

1. STT — Speech-to-Text em PT-PT

Comparação directa

Serviço PT-PT Latência streaming Custo/hora Modo Nota
--- --- --- --- --- ---
Deepgram Nova-3  Explícito (pt-PT) ~120–200ms ~\$0.36/h Streaming nativo Melhor opção RTT
ElevenLabs STT (Scribe v2)  90+ línguas ~150ms ~\$0.36/h Streaming WebSocket Stack ElevenLabs unificado
OpenAI Whisper (batch)   (sem stream nativo) \$0.006/min Batch GPT-Realtime-Whisper lançado Maio 2026 a \$0.017/min mas não testado PT-PT
OpenAI GPT-Realtime-Whisper Provável ~200–300ms \$1.02/h Streaming Novo (Maio 2026), sem benchmarks PT-PT
AssemblyAI Universal-Streaming  (beta) ~300ms \$0.15/h base Streaming PT-PT em beta — risco para produção
Gladia  (100+ línguas) ~300ms ~\$0.54/h Streaming Bom para multilingue, não especializado PT-PT
Whisper local (faster-whisper)  ~200–500ms (CPU) \$0 Batch/local No Mac Mini sem GPU: latência elevada

Conclusão STT

Deepgram Nova-3 com `language=pt-PT` continua a ser a escolha certa — já está integrado, melhorou especificamente PT-PT em Maio 2026 (WER -54% vs competidores), streaming sub-200ms, \$0.36/h.

ElevenLabs Scribe v2 é uma alternativa válida se migrares para o ecossistema deles (150ms, WebSocket, mesmo preço). Vantagem: uma só conta, uma só fatura.

2. TTS — Text-to-Speech com voz emocional e humana

Comparação directa

| Serviço | PT-PT nativo | Clonagem de voz | TTFA | Custo/1k chars | Nota emocional |

|---|---|---|---|---|

| **ElevenLabs v3** | ■ (clonagem funciona PT) | ■ Morgan Freeman clonado | ~80–150ms | \$0.30 (Pro) | **Melhor qualidade emocional** — model v3 com prosódia, riso real, pausas naturais |

| **Cartesia Sonic 3.5** | ■ (PT incluído) | ■ (amostra 3s) | **40–82ms** | ~\$0.15 | Mais rápida do mercado — menos emocional que ElevenLabs v3 |

| **OpenAI TTS (tts-1-hd)** | Razoável | ■ | ~200ms | \$0.12–0.30 | Voz genérica, sem emoção real |

| **PlayHT 3.0** | ■ | ■ | ~100ms | \$0.18 | Boa qualidade, menos madura que ElevenLabs |

| **Kokoro-82M (open-source)** | ■ (PT-BR principalmente) | ■ | ~200ms CPU | \$0 | PT-PT fraco — vozes principais são EN; inviável para Morgan |

| **Hume Octave 2** | ■ (PT suportado) | Limitado | ~150ms | Incluído no EVI 4 | Emoção integrada mas voz menos personalizável |

ElevenLabs Conversational AI — análise a fundo

A plataforma deles integra STT + LLM + TTS num único WebSocket, com:

- Modelo de voz: Eleven v3 Conversational — otimizado para diálogo real-time
- Suporte PT: confirmado (74 línguas), mas feedback de campo diz que PT-PT < PT-BR em qualidade de clonagem — **testar antes de comprometer**
- Preço: **\$0.08–0.12/minuto** — inclui STT + LLM + TTS
- Com 1h/dia de uso: ~\$4.80–7.20/dia → **~€130–200/mês** — caro para uso pessoal intenso
- O LLM que usam por defeito é deles (não é Claude) — podes trazer o teu próprio LLM via webhook, mas adiciona latência
- Vantagem principal: latência total muito baixa (sub-500ms end-to-end) com pipeline otimizado

Conclusão TTS

ElevenLabs v3 via API direta (não o Conversational AI platform) dá-te a melhor qualidade emocional com a voz Morgan Freeman já clonada, a \$0.30/1k chars. Para textos médios de conversação (~150 chars por resposta), custa ~\$0.045 por resposta — praticável.

3. LLM com inteligência emocional

O que existe

| Abordagem | Capacidade emocional | PT-PT | Custo/1k tokens | Recomendação |

|---|---|---|---|

| **Claude Sonnet 4.6 com system prompt elaborado** | Alta (instruct) | ■ | ~\$0.003 in / \$0.015 out | **Recomendado** — já usas, controlas o prompt |

| **Claude Opus 4.8** | Muito alta | ■ | ~\$0.015 in / \$0.075 out | Para decisões estratégicas, não conversação |

| **Hume EVI 4-mini** | Muito alta (emocional nativo) | ■ PT suportado | Incluído no plan | Emoção é o seu diferencial — mas voz menos personalizável |

| **GPT-4o Realtime** | Alta | Razoável | \$0.10/min audio | Voz nativa OpenAI, não clonável facilmente |

| **Play AI / Tavus** | Média | Limitado | Variável | Orientados a avatares, não assistente pessoal |

Como construir "memória emocional"

O Morgan já tem Qdrant Cloud e `memory/episodic_memory.json`. A estratégia certa:

1. **Perfil emocional base** — JSON persistente com padrões do Vasco (hora do dia, contexto Moreirense, trading em alta/baixa)
2. **Contexto de sessão** — nos últimos 5 minutos de conversa, detectar palavras/padrões de frustração, euforia, cansaço
3. **System prompt dinâmico** — o CEO monta o prompt com "estado actual: [cansado após treino] [Moreirense perdeu ontem]" → Claude responde em conformidade
4. **Qdrant semântico** — guardar resumos de conversas emocionalmente relevantes, recuperar no início de cada sessão

Exemplo de system prompt emocional:

`

És o Morgan — não um assistente, um irmão mais velho que conhece o Vasco há anos.

Estado actual do Vasco: [cansado, treino difícil às 10h].

Última conversa relevante: [ontem estava frustrado com o trading].

Adapta o tom: directo, sem floreios, sem validação vazia.

Se discordas, diz. Se há más notícias, dá-as claramente.

Fala como se estivesses no sofá ao lado dele, não como um chatbot.

`

4. Architecturas possíveis

A) ElevenLabs Conversational AI (end-to-end)

`

Browser mic → ElevenLabs WebSocket (STT+LLM+TTS integrado) → áudio

`

|||

|---|---|

| **Latência total** | ~400–600ms (end-to-end) |

| **Custo/mês (1h/dia)** | ~€130–200/mês |

| **Complexidade implementação** | 3/10 — já tens o proxy em `desktop_server.py` |

| **Qualidade** | 8/10 — boa mas LLM deles ≠ Claude, voz v3 excelente |

| **Problema principal** | LLM nativo deles não é Claude; trazer Claude via webhook adiciona latência e custo; PT-PT pode ser menos polido que PT-BR |

B) Pipeline próprio — Deepgram STT → Claude API → ElevenLabs TTS

`

Mic → Deepgram Nova-3 stream (PT-PT) → buffer de frase → Claude Sonnet → ElevenLabs v3 stream → áudio

`

|||

|---|---|

| **Latência total** | ~600–900ms (realista com streaming sentence-by-sentence) |

| **Custo/mês (1h/dia)** | ~€25–40/mês (Deepgram + Claude + ElevenLabs) |

| **Complexidade implementação** | 6/10 — pipeline novo mas código modular |

| **Qualidade** | 9/10 — melhor LLM, melhor voz, total controlo |

| **Vantagem** | Controlo total; Claude com memória emocional real; voz Morgan Freeman clonada; PT-PT nativo em cada camada |

Estimativa de custos com 1h/dia:

- Deepgram: 30h/mês × \$0.36 = **\$10.80**
- Claude Sonnet: ~1000 mensagens/mês × ~500 tokens = \$7.50 in + \$37.50 out ≈ **\$45** (upper bound)
- ElevenLabs TTS: ~150 chars/resposta × 1000 respostas × \$0.30/1k = **\$45**
- Total: ~\$100/mês (~€90)** — pode otimizar com cache de respostas comuns

C) Pipeline open-source local (Mac Mini)

`

Mic → faster-whisper local (CPU) → Ollama (LLM local) → Kokoro TTS → áudio

`

|||

|---|---|

| **Latência total** | ~1500–3000ms no Mac Mini sem GPU |

| **Custo/mês** | ~€5–11 (só electricidade) |

| **Complexidade implementação** | 8/10 — setup complexo, manutenção alta |

| **Qualidade** | 5/10 — Kokoro PT fraco; LLMs locais 8B << Claude |

| **Problema principal** | Mac Mini sem GPU Apple Silicon (é Intel?) → Whisper lento; Kokoro sem PT-PT nativo; LLM local não tem capacidade do Claude |

Não recomendado para uso diário do Morgan.

D) Hume EVI 4-mini

、

Browser mic → Hume EVI 4-mini WebSocket (PT suportado) → áudio

、

|||

|---|---|

| **Latência total** | ~500–700ms |

| **Custo/mês** | ~\$0.06/min → ~€100/mês (1h/dia) |

| **Complexidade implementação** | 4/10 — API similar ao EVI 2 |

| **Qualidade emocional** | 9/10 — é o diferencial deles |

| **Problema principal** | PT-PT em EVI 4-mini: confirmado suportado, mas qualidade não benchmarked; voz não é a Morgan Freeman clonada; EVI 2 que tinha estava quebrado, EVI 4 é diferente |

Interessante como alternativa futura, mas requer teste de qualidade PT-PT antes de comprometer.

E) Híbrida — ElevenLabs STT + Claude + ElevenLabs TTS v3

、

Mic → ElevenLabs Scribe v2 stream (150ms) → Claude Sonnet (memória emocional) → ElevenLabs v3 TTS stream → áudio

、

|||

|---|---|

| **Latência total** | ~500–700ms |

| **Custo/mês** | ~€70–90/mês |

| **Complexidade implementação** | 5/10 — duas APIs ElevenLabs + Claude |

| **Qualidade** | 9/10 — mesma qualidade que B mas STT unificado na conta ElevenLabs |

| **Vantagem** | Uma conta, uma fatura; STT deles é 150ms (melhor que Deepgram para este uso); Claude mantém-se |

5. Recomendação Final

Arquitetura escolhida: E — ElevenLabs STT (Scribe v2) + Claude Sonnet + ElevenLabs TTS v3

Porquê esta e não a B:

- ElevenLabs STT Scribe v2 tem 150ms (melhor que Deepgram's 200ms para este uso)
- Uma conta, uma fatura, um SDK — simplifica manutenção
- A voz Morgan Freeman está já clonada na mesma conta
- Claude Sonnet com system prompt emocional é imbatível como "irmão"
- Deepgram mantém-se como fallback se ElevenLabs STT tiver problemas

Porquê não o Conversational AI platform (A):

- \$130–200/mês vs €70–90 com a arquitectura E
- LLM deles ≠ Claude → perdes toda a inteligência emocional customizada
- Menos controlo sobre memória, system prompt, contexto do Vasco

Plano de implementação

Ficheiros a criar/modificar:

`

Morgan/

■■■■ voice_pipeline.py NOVO — pipeline E2E com ElevenLabs STT + Claude + ElevenLabs TTS

■■■■ voice_emotional_context.py NOVO — constrói system prompt com estado emocional do Vasco

■■■■ desktop_server.py MODIFICAR — substituir Hume EVI por voice_pipeline

■■■■ memory/

■■■■ emotional_profile.json NOVO — perfil emocional persistente do Vasco

`

voice_pipeline.py — **estrutura:**

`python

async def voice_session(websocket):

1. ElevenLabs Scribe v2 WebSocket (STT stream)
2. Detectar fim de frase (silence + punctuation)
3. Construir contexto emocional via voice_emotional_context.py
4. Claude Sonnet API (streaming, sentence-by-sentence)
5. Por cada frase → ElevenLabs TTS v3 stream → áudio para browser

`

voice_emotional_context.py — **lógica:**

`python

def build_emotional_prompt(hora: int, last_matches: list, trading_pnl: float) -> str:

Detectar contexto: após treino, noite, fim de semana, etc.

Recuperar últimas notas emocionais do Qdrant

Retornar system prompt personalizado

,

Custo mensal estimado

| Componente | Custo/mês (1h/dia) |

|---|---|

| ElevenLabs STT (Scribe v2) | ~\$12 |

| Claude Sonnet 4.6 | ~\$30–45 |

| ElevenLabs TTS v3 | ~\$35–45 |

| **Total** | ~€70–90/mês |

Optimizações para reduzir: cache de respostas repetidas (briefings de manhã), Claude Haiku para respostas curtas (< 2 frases), limitar TTS a respostas > 10 palavras (resto em texto).

Prazo para voz funcional em PT-PT com qualidade "irmão"

| Fase | O que fazer | Prazo |

|---|---|---|

| **Fase 1** (2–3h) | `voice_pipeline.py` com STT + Claude + TTS; integrar em `desktop_server.py`; testar PT-PT básico | 1 sessão |

| **Fase 2** (3–4h) | `voice_emotional_context.py`; `emotional_profile.json`; system prompt dinâmico com hora/contexto | 1 sessão |

| **Fase 3** (1–2h) | Tuning: velocidade da voz ElevenLabs (stability, similarity_boost, style), silêncio entre frases, detecção de fim de turn | 1 sessão |

| **Total** | Voz funcional e emocional | **2–3 sessões de trabalho** |

Como integrar no `desktop_server.py` existente

O código actual já tem:

- `gerar_audio_elevenlabs()` — manter, usar para TTS
- Proxy WebSocket Hume EVI — **substituir** por `voice_pipeline.py`
- `ELEVENLABS_VOICE_ID` e `ELEVENLABS_KEY` — já presentes, reutilizar

Mudança principal: substituir o handler `/ws/hume` por `/ws/voice` que usa o novo pipeline. O browser (`desktop/index.html`) liga ao mesmo endpoint, muda só o URL.

Notas finais

- ElevenLabs STT PT-PT**: confirmado suportado (90+ línguas, WebSocket 150ms) mas qualidade específica PT-PT vs PT-BR requer teste prático de 10 minutos antes de comprometer
- Hume EVI 4-mini**: merece um teste paralelo — emoção nativa é o seu diferencial; se PT-PT for bom, pode ser opção futura para substituir camada de LLM
- Cartesia**: ideal se a latência for crítica (40ms TTFA vs 80ms ElevenLabs) mas emoção é inferior; não recomendado dado que o objectivo é qualidade "irmão", não velocidade máxima
- Kokoro local**: descartar — PT-PT fraco, sem GPU no Mac Mini, manutenção elevada

Gerado: 8 Agosto 2026 | Scout Morgan | Versão 1.0

Gerado por Morgan CEO · BCVertex · 08/08/2026